

Fine-Tuning MobileNetV3-Small Untuk Deteksi Hama Parasitoid Pada Tanaman Daun Sawi Hijau

UUNG UNGKAWA ¹, RIDDHO PUTRA MUHARAM ²

^{1, 2} Program Studi Informatika Institut Teknologi Nasional Bandung
Email: uung@intenas.ac.id

Received xx Juli 201x | *Revised* xx Juli 201x | *Accepted* xx Juli 201x

ABSTRAK

Sawi hijau merupakan komoditas sayuran yang mengandung zat-zat bernutrisi tinggi bagi kebutuhan masyarakat. Namun, budidayanya rentan terhadap serangan hama. Pentingnya penanganan hama sejak dini tidak bisa diabaikan, agar meminimalisir kerugian dan dampak negatif pada sawi. Deteksi hama umumnya masih mengandalkan mata manusia, yang memakan waktu, rentan terhadap kelalaian, dan tidak efisien. Untuk mempermudah deteksi hama parasitoid di lapangan, penelitian ini menghadirkan solusi inovatif berbasis perangkat mobile dengan mengimplementasikan Convolutional Neural Network arsitektur MobileNetV3-Small, yang secara spesifik dirancang untuk mendeteksi hama pada tempat budidaya sawi secara langsung. Pada penelitian ini, arsitektur MobileNetV3-Small dengan learning rate 0.00001, epoch 50 dan batch size 8 menghasilkan kinerja model terbaik dengan nilai akurasi 98.67%, precision 0.99, recall 0.99, dan f1-score 0.99.

Kata kunci: Deteksi hama, Sawi Hijau, *CNN*, *MobileNetV3-Small*, *mobile*

ABSTRACT

Green mustard is a highly nutritious vegetable commodity essential for public consumption. However, its cultivation is susceptible to pest attacks. Early pest management is crucial to minimize losses and negative impacts on the mustard plants. Typically, pest detection still relies on human observation, which is time-consuming, prone to oversight, and inefficient. To facilitate the detection of parasitoid pests in the field, this research presents an innovative mobile-based solution that implements the Convolutional Neural Network (CNN) MobileNetV3-Small architecture. This architecture is specifically designed for direct pest detection in green mustard cultivation areas. In this study, the MobileNetV3-Small architecture, with a learning rate of 0.00001, 50 epochs, and a batch size of 8, yielded the best model performance with an accuracy of 98.67%, precision of 0.99, recall of 0.99, and an f1-score of 0.99.

Keywords: *pest detection, green mustard, CNN, MobileNetV3-Small, mobile*

1. PENDAHULUAN

Tanaman sawi hijau (*Brassica rapa var. parachinensis* L.) merupakan salah satu komoditas sayuran yang sangat populer di kalangan masyarakat. Dikenal kaya akan zat gizi, sawi hijau menjadi bagian penting dalam pemenuhan nutrisi dan ketahanan pangan. Permintaan terhadap sawi terus meningkat seiring dengan pertumbuhan populasi dan kesadaran akan gizi. Namun, di sisi lain, produktivitas sawi di Indonesia masih tergolong rendah dan belum sepenuhnya memenuhi kebutuhan pasar. Salah satu faktor utama yang menghambat peningkatan produksi dan kualitas sawi adalah serangan hama [1].

Tanaman sawi hijau sendiri memiliki penyakit atau hama pada tanaman di mana hal tersebut merupakan hal yang sangat dihindari oleh petani yang menanam tanaman sawi, karena akan menjadi suatu kerugian atau gagal panen. Penyebab munculnya hama pada tanaman sawi yaitu kelembaban, sirkulasi udara, kondisi tanah dan varietas tidak tahan hama [2]. Salah satu hama utama dalam budidaya tanaman sawi hijau adalah ulat tritip (*Plutella xylostella* L.). Larva *P. xylostella* merusak tanaman sawi hijau dengan memakan permukaan daun bagian bawah hingga menghabiskan semua daun bahkan dapat menyisakan tulang daun saja [3]. Hama dapat menyebabkan berkurangnya kualitas daun sawi hijau untuk dikonsumsi serta memperpendek umur simpan sawi hijau sehingga berpengaruh pada daya jual sawi hijau [4]. Pentingnya penanganan hama sejak dini tidak bisa diabaikan, untuk meminimalisir kerugian dan dampak negatif terhadap kualitas sawi. Biasanya proses mendeteksi hama dilakukan secara manual berdasarkan pengamatan secara langsung pada objek, klasifikasi dengan menandakan pengamatan visual manusia yang bersifat objektif biasanya memiliki beberapa kelemahan yakni, adanya keterbatasan visual manusia, dan sifat merasa cepat lelah ketika melakukan kegiatan yang berulang [5]. Mengingat masalah serangan hama pada sawi hijau, diperlukan deteksi inovatif dan efisien. Teknologi kecerdasan buatan, khususnya deep learning untuk analisis citra, hadir sebagai solusi potensial. Diharapkan sistem ini mampu mencapai akurasi deteksi tinggi dan, yang terpenting, mendeteksi hama parasitoid secara efektif menggunakan perangkat mobile.

Deep learning merupakan bagian dari Machine Learning yang terdiri dari input layer, hidden layer dan yang bekerja berdasarkan multi-layer neural network, yang dimana model dapat mempelajari banyak lapisan yang memiliki nilai representatif pada pemrosesan fitur [6]. Deep learning merujuk pada sebuah pendekatan dalam pembelajaran mesin yang memanfaatkan arsitektur jaringan saraf tiruan berlapis-lapis. Karakteristik utama dari pendekatan ini adalah kemampuannya dalam mengekstraksi representasi fitur yang semakin kompleks dari data masukan melalui kedalaman lapisannya [7].


Pada penelitian pendeteksian hama pada tanaman sawi hijau dapat dilakukan dengan berbagai macam metode seperti *Convolutional Neural Network* (CNN) yang telah banyak digunakan dan mendapatkan hasil yang baik, terdapat beberapa penelitian mengenai deteksi hama pada tanaman sawi, diantaranya penelitian ini menerapkan beberapa arsitektur *Convolutional Neural Network* (CNN) untuk mendeteksi hama pada tanaman sawi hijau. Pada penelitian tersebut mendapatkan hasil akurasi pada percobaan A-CNN *from scratch* sebesar 48.33%, percobaan B-CNN *from scratch* sebesar 73.00%, percobaan C-CNN *from scratch* sebesar 92.00%, D-CNN add model VGG16 sebesar 95,00%, dan percobaan E-CNN add model Xception sebesar 97.00%, dan juga percobaan F-CNN add model NASNetMobile sebesar 93.00% [8].

Berkaitan dengan masalah yang sudah dipaparkan diatas, digunakan beberapa arsitektur *Convolutional Neural Network* (CNN) dalam studi kasus pendeteksian hama daun sawi nilai yang cukup baik dari 6 percobaan arsitektur yang digunakan. Maka pada penelitian ini akan

digunakan metode MobileNetV3-Small sebagai pembaharuan dari metode sebelumnya untuk mendapatkan hasil yang lebih baik dan dapat membantu memberikan solusi deteksi hama yang mudah diakses dan dapat diterapkan langsung di lapangan, baik untuk area budidaya sawi yang sempit maupun luas, melalui pemanfaatan perangkat mobile.

2. METODE PENELITIAN


Metode penelitian merupakan pendoman dalam melaksanakan penelitian. Adanya metode penelitian, alur dan hasil penelitian dapat tercapai, serta tidak menyimpang dari tujuan yang telah ditentukan. Langkah-langkah yang dilakukan pada proses pembuatan system, dapat dilihat pada gambar 1.



Gambar 1. Alur Proses Metode Penelitian

2.1 Blok Diagram

Tahap awal perancangan alat adalah membuat sebuah blok diagram. Desain blok diagram menunjukkan cara kerja alat secara keseluruhan, mulai dari input, proses, hingga output [9]. Blok diagram merupakan suatu alur dari sistem secara sederhana yang bertujuan untuk menerangkan dari cara kerja sistem yang dibuat pada gambar 2.



Gambar 2. Blok diagram

Pada Gambar 2 menampilkan blok diagram dengan alur kerja sistem secara keseluruhan. Pada sistem tersebut akan menggunakan algoritma Convolutional Neural Network (CNN) sebagai pengidentifikasi hama pada tanaman sawi hijau.


Berdasarkan Gambar 2 terdapat beberapa tahapan, yaitu sebagai berikut:

1. Input berupa citra gambar daun sawi.
2. Dilakukan proses pembagian dataset menjadi data training dan data validasi dan data test.

3. Selanjutnya dilakukan proese preprocessing pada citra dengan dilakukan resize image mejadi 224x224x3.
4. Dilakukan augmentasi data citra menggunakan ImageDataGenerator dengan melakukan horizontal flip, rotation range, width shift, height shift, zoom range, shear range dan fill_mode.
5. Selanjutnya dilakukan proses pelatihan model menggunakan arsitektur MobileNetV3-Small dengan operasi umum seperti konvolusi, pooling, dan perhitungan nilai loss menggunakan Cross Entropy dan klasifikasi menggunakan softmax.
6. Model yang sudah dilakukan pelatihan maka dilakukan evaluasi kinerja model untuk mengukur kinerja model berdasarkan hasil dari confusion matrix, f1- score, presicion dan recall kemudian dihasilkan akurasi pengujian model.
7. Kemudian model hasil pelatihan digunakan untuk mengidentifikasikan citra pada citra data uji.
8. Output yang dihasilkan yaitu berupa hasil tanaman sawi hijau.

2.2. Flowchart Sistem

Pada sistem ini menggunakan arsitektur MobilenetV3 dalam pembentukan model deteksi hama parasitoid pada tanaman sawi hijau dengan beberapa tahapan proses pembentukan model. Berikut flowchart system ditunjukan pada gambar 3.



Gambar 3 Merupakan Flowchart Sistem

Pada gambar 3 terdapat beberapa tahapan yaitu :

1. Input citra sawi.
2. Kemudian citra di preprocessing citra resize (224x224x3).
3. Sesudah di resize citra, maka dilakukan tahapan augmentasi citra yaitu, geser, perbesar, dan rotasi.

4. Sesudah itu dilakukan pengambilan Pre-Trained ImageNet, atau mengambil model yang sudah dilatih sebelumnya.
5. Selanjutnya konfigurasi hyperparameter seperti Epoch, Learning Rate, Dan Juga Batch Size.
6. Sesudah di konfigurasi, maka dilakukan training oleh arsitektur MobileNetV3.
7. Kemudian dilakukan proses operasi pooling yaitu average pooling.
8. Dilakukan dropout untuk mengurangi ukuran loss dari model.
9. Masuk proses klasifikasi dengan menggunakan softmax.
10. Selesai.

2.3. Persiapan Dataset

Dataset yang digunakan berupa citra tanaman daun sawi hijau yang didapatkan dari *website* Kaggle. Dataset yang digunakan terdiri dari 1000 citra daun sawi hijau yang dikelompokkan menjadi dua kelas, yaitu Daun Sawi Tanpa Hama, dan Daun Sawi Ada Hama dengan masing-masing kelas terdiri dari 500 data. Berikut dataset daun sawi hijau ditunjukkan pada Tabel 1.

Tabel 1. Penggunaan Dataset

No	Kelas	Gambar	Jumlah Data	Deskripsi
1	Hama		500	Daun sawi hijau yang terkena hama parasitoid
2	Tanpa Hama		500	Daun sawi hijau yang tidak terkena hama
Total Dataset			1000	

2.4. Pembagian Data

Kumpulan data dibagi menjadi tiga kategori : data train, data validasi, dan data test. Pada tabel 2 merinci struktur pembagian data. Kemudian label ditambahkan pada setiap gambar sehingga kelas dapat diidentifikasi.

Tabel 2. Kategori pembagian dataset

Tippe Data	Jumlah Data
Data Train	70%
Data Validasi	20%
Data Test	10%

2.5. MobileNetV3-Small

MobileNetV3 merupakan suatu struktur jaringan saraf tiruan yang didesain khusus untuk aplikasi dengan kebutuhan pemrosesan yang ringan pada perangkat mobile [10]. MobileNetV3 merupakan arsitektur CNN yang termasuk efisien dari komputasi yang rendah, MobileNetV3 adalah hasil peningkatan dari versi sebelumnya yakni MobileNetV1 dan MobileNetV2, pada MobileNetV3 ditambahkan fitur Depthwise Separable Convolution dan Batch Normalization [11], yang dimana kedua fitur tersebut mengurangi komputasi dan mempercepat proses pelatihan; *Linear Bottlenecks* dan *Inverted Residual* [12]. *MobileNetV3* memiliki 2 jenis model yaitu *MobileNetV3-Large* dan *MobileNetV3-Small* yang dimana perbedaan keduanya terdapat pada jumlah dan jenis layer yang dipakai [13], Untuk mempercepat proses belajarnya model dan memanfaatkan fitur-fitur yang telah di pelajari dataset yang sangat besar, arsitektur MobileNetV3-Small ini di inisialisasi dengan bobot pre-trained dari dataset ImageNet. pada tabel 3 merupakan arsitektur MobileNetV3-Small.

Tabel 3. Arsitektur MobileNetV3 Small.

Input	Layer	Expensive Size	Out	SE Block	Non Linear	Stride
$224^2 \times 3$	Conv2d 3x 3	-	16	-	HS	2
$112^2 \times 16$	Bneck, 3 x 3	16	16	√	RE	2
$56^2 \times 16$	Bneck, 3 x 3	72	24	-	RE	2
$28^2 \times 24$	Bneck, 3 x 3	88	24	-	RE	1
$28^2 \times 24$	Bneck, 5 x 5	96	40	√	HS	2
$14^2 \times 40$	Bneck, 5 x 5	240	40	√	HS	1
$14^2 \times 40$	Bneck, 5 x 5	240	40	√	HS	1
$14^2 \times 40$	Bneck, 5 x 5	120	48	√	HS	1
$14^2 \times 48$	Bneck, 5 x 5	144	48	√	HS	1
$14^2 \times 48$	Bneck, 5 x 5	288	96	√	HS	2
$7^2 \times 96$	Bneck, 5 x 5	576	96	√	HS	1
$7^2 \times 96$	Bneck, 5 x 5	576	96	√	HS	1
$7^2 \times 96$	Conv2d 1x1	-	576	√	HS	1
$7^2 \times 576$	Pool, 7 x 7	-	-	-	-	1
$1^2 \times 576$	Conv2d 1 x 1 NBN	-	1024	-	HS	1
$1^2 \times 1024$	Conv2d 1 x 1 NBN	-	k	-	-	1

Tahapan proses MobileNetV3 adalah sebagai berikut:

1. Langkah pertama melibatkan penggunaan konvolusi 2D, *kernel 3x3*, *stride 2*, dan fungsi aktivasi *hard-swish* pada gambar 224x224 dengan tiga *channel* warna—merah, hijau, dan biru. *Hard-swish* memberikan keseimbangan yang baik antara non-linearitas dan kesederhanaan, sehingga cocok untuk arsitektur ringan seperti MobileNetV3.
2. *Bottleneck 3x3* digunakan untuk melakukan proses konvolusi. Pertama, konvolusi 1x1 diterapkan pada masukan untuk mengurangi dimensi. Karena dimensinya yang lebih rendah, konvolusi 3x3 dapat memproses fitur konvolusi dengan lebih mudah.
3. Selanjutnya, konvolusi 1x1 diterapkan pada *output* untuk memastikan bahwa dimensi kembali ke *input* (*residual bottleneck function*). Terakhir, ReLU digunakan sebagai fungsi aktivasi untuk menambahkan nonlinier dan meningkatkan representasi model.
4. Ini adalah *bottleneck layer*, layer ini memiliki 11 jumlah lapisan, dan satu-satunya perbedaan antara setiap lapisan adalah ukuran *kernel*, fungsi aktivasi, dan parameter *stride*.
5. Berikutnya, ada metode bernama *7x7 pooling* yang berfungsi untuk memperkecil dimensi *feature map*, menurunkan jumlah parameter yang dapat dipelajari, dan menurunkan beban komputasi jaringan.
6. Selanjutnya, konvolusi *kernel 1x1 2d* dengan fungsi aktivasi *hard-swish* dan tidak ada *batch normalization* yang digunakan.
7. Lapisan yang sama terdapat pada lapisan terakhir, namun tujuannya berbeda karena berfungsi sebagai *output* citra.

2.6. Metrik Evaluasi

Perhitungan nilai akurasi pada pembelajaran mesin biasa disebut dengan konfusi matriks (*Confusion Matrix*). Pada dasarnya, konfusi matriks memberikan informasi perbandingan hasil klasifikasi yang dilakukan oleh sistem dalam bentuk model dengan hasil klasifikasi sebenarnya. Pada bagian ini ada beberapa matriks performansi yang umum dan sering digunakan, yaitu *accuracy*, *precision*, dan *recall* [14].

Akurasi dan F1 Score merupakan data yang digunakan untuk mengecek keberhasilan model. Pengecekan akurasi dan F1 Score dihitung menggunakan confusion matrix. [15]

Terdapat beberapa hasil yang dapat diambil dari confusion matrix untuk menentukan keberhasilan sebuah model, diantaranya:

1. Accuracy, merupakan rasio prediksi benar (positif dan negative) seberapa akurat model dalam mengklasifikasikan dengan benar. Adapun persamaan (1) sebagai berikut:

$$Accuracy = \frac{TP + TN}{TP + FP + FN + TN} \times 100\% \quad (1)$$

2. Precision, merupakan gambaran seberapa akurat antara data yang diminta dengan hasil prediksi yang diberikan oleh model. Adapun persamaan (2) sebagai berikut:

$$Precision = \frac{TP}{TP + FP} \times 100\% \quad (2)$$

3. Recall, merupakan gambaran keberhasilan model dalam menemukan Kembali sebuah informasi. Adapun persamaan (3) sebagai berikut:

$$Recall = \frac{TP}{TP + FN} \times 100\% \quad (3)$$

4. F1 Score, merupakan gambaran perbandingan rata-rata precision dan recall yang dibobotkan. Adapun persamaan (4) sebagai berikut:

$$F1\ Score = \frac{Recall \times Precision}{Recall + Precision} \times 100\% \quad (4)$$

3. HASIL DAN PEMBAHASAN

Pengujian system dalam mendeteksi hama parasitoid yang terdapat pada citra menggunakan metode *convolutional neural network* dengan arsitektur MobileNetV3-Small. Implementasi ini dilakukan dengan menggunakan mesin *google collaboratory*. Tensorflow dan keras sebagai penunjang dari penelitian ini.


3.1. Hasil Pelatihan

Proses pelatihan menggunakan gambar data train dan validasi, pada penelitian ini bertujuan untuk mendeteksi hama parasitoid pada citra daun sawi hijau, pada pelatihan model ini tidak hanya menggunakan satu nilai *batch size* dan *learning rate* tetapi terdapat nilai lainnya yang sudah ditentukan yang bertujuan untuk menghasilkan model yang terbaik. Berikut beberapa hasil nilai dari parameter dengan batch size yang berbeda dengan epoch 50 yang ditunjukkan pada Tabel 4.

Tabel 4. Perbandingan Accuracy dan Loss pada Learning rate dan Batch size

No	Epoch	Batch Size	Learning Rate	Accuracy %	Loss %
A1	50	8	0.001	99.40%	0.0122
A2			0.0001	99.34%	0.0253
A3			0.00001	98.67%	0.0688
A4		16	0.001	99.68%	0.0184
A5			0.0001	99.69%	0.0101
A6			0.00001	99.74%	0.0136
A7		32	0.001	99.27%	0.0183
A8			0.0001	99.69%	0.0198
A9			0.00001	94.99%	0.1640

Berikut adalah hasil penelitian dengan hyperparameter epoch 50 ditunjukkan pada Gambar 5.




Gambar 5. Grafik akurasi dan loss dengan epoch 50.

Dari beberapa pelatihan yang dilakukan, dapat disimpulkan bahwa metode MobileNetV3-Small terbukti menghasilkan akurasi yang sangat baik dalam mendeteksi hama parasitoid pada tanaman daun sawi hijau. Namun, penggunaan hyperparameter berpengaruh pada stabilitas model, penggunaan learning rate 0,001 dan juga 0.0001 menghasilkan nilai akurasi yang bagus tetapi banyak terjadi overfitting yang cukup signifikan. Untuk penggunaan hyperparameter dengan batch size 8 dan learning rate 0,00001 menunjukkan grafik yang cukup stabil dari awal hingga epoch terakhir, maka dipastikan untuk model A3 adalah model yang terbaik pada penelitian ini, dan mendapatkan hasil akurasi sebesar 98,67%.

3.2. Evaluasi Model

Berikut adalah evaluasi model A3 yang dihasilkan saat pelatihan kemudian dapat dievaluasi menggunakan grafik confusion matrix yang ditunjukkan pada gambar 6.



Gambar 6. Hasil Evaluasi Confusion Matrix Model A3.

Confusion Matrix pada model A3 terlihat diagonal yang artinya model berhasil memprediksi seluruh kelas yang ada pada dataset.

1. Hama : Dari 50 data test, semua gambar untuk kelas hama terprediksi benar.
2. Tanpa Hama : Dari 50 data test, 49 gambar terprediksi benar, 1 gambar terprediksi sebagai kelas hama.


Selain itu *nilai accuracy, precision, recall, dan f1-score* juga diperoleh melalui pelatihan ini. Tabel 4 mewakili nilai *precision, recall, dan f1-score* pada model A3.

Tabel 4. Evaluasi Klasifikasi Model A3.

Model A3	Accuracy	Precision	Recall	F1-Score
Hasil	98.67%	0.99	0.99	0.99

3.3. Implementasi Model

Dari hasil model yang telah dilatih, dibuatlah gradio, yang telah terbukti berfungsi dengan baik dalam memfasilitasi penggunaan model [16]. Berikut hasil model yang telah dilatih menggunakan MobileNetV3-Small dan di implementasikan menggunakan gradio pada gambar 7.



Gambar 7. Merupakan hasil model menggunakan gradio.

4. KESIMPULAN

Berdasarkan hasil penelitian yang telah dilakukan mulai dari studi literatur, implementasi hingga pengujian dapat disimpulkan bahwa model MobileNetV3-Small untuk deteksi hama parasitoid pada tanaman sawi hijau dapat mendeteksi hama dengan baik pada hyperparameter epoch 50, batch size 8, dan learning rate 0.00001 dengan mendapatkan akurasi 98.67%. Adapun saran untuk pengembang selanjutnya adalah dengan mengimplementasikan secara real-time dalam mendeteksi hama parasitoid.

DAFTAR RUJUKAN

- [1] Akyuni, D. (2021). PERBANDINGAN VARIASI LIMBAH CAIR DAN AMPAS TAHU TERHADAP PERTUMBUHAN TANAMAN SAWI HIJAU (*Brassica rapa* var. *parachinensis* L.) . *UNDISKHA REPOSITORY*, 1-6.
- [2] Somba, Y. P. (2023). Deteksi Hama Pada Tanaman Sawi Dengan Algoritma CNN. *De La Salle*, 1-5.
- [3] Syarifah Tuti Alawiyah, Y. R. (2023). Jenis dan Tingkat Parasitasi Parasitoid Larva *Plutella xylostella* L. pada Tanaman Sawi Hijau (*Brassica juncea* L.). *Jurnal Media Pertanian*, 1-8.
- [4] NANILETTE, L. (2023). IDENTIFIKASI PENYAKIT DAN HAMA PADA DAUN TANAMAN SAWI HIJAU (*Brassica juncea* L.) DI PERKEBUNAN WAIHERU KOTA AMBON. *JAIN Ambon*, 1-47.
- [5] Ishak, I. A. (2022). Sistem Pendeteksi Kematangan Buah Tomat Berbasis Pengolah Citra Digital Menggunakan Metode Jaringan Syaraf Tiruan. *Jurnal MediaTIK : Jurnal Media Pendidikan Teknik Informatika Dan Komputer*, 65-69.
- [6] Ian Goodfellow, Y. B. (2016). *Deep Learning*. Cambridge: Massachusetts.
- [7] Emi Sita Eriana, S. M. (2023). ARTIFICIAL INTELLIGENCE (AI). Dalam S. M. Emi Sita Eriana, *ARTIFICIAL INTELLIGENCE (AI)* (hal. 1-125). JAWA TENGAH: PENERBIT CV. EUREKA MEDIA AKSARA .
- [8] Nazalia, C. L. (2022). IMPLEMENTASI ALGORITMA CONVOLUTIONAL NEURAL NETWORK UNTUK DETEKSI HAMA PADA TANAMAN SAWI HIJAU. *Institut Teknologi PLN*, 1-109.
- [9] Arinda Rifaini, S. S. (2021). ALAT PERANGKAP DAN KAMERA PENGAWAS DENGAN MENGGUNAKAN ESP32-CAM SEBAGAI SISTEM KEAMANAN KANDANG AYAM. *Jurnal Teknik dan Sistem Komputer (JTikom)*, 53-63.
- [10] Andrew G. Howard, M. Z. (2017). MobileNets: Efficient Convolutional Neural Networks for Mobile Vision Application. *arXiv:1704.04861v1 [cs.CV]*, 1-9.
- [11] Andrew Howard, M. S.-C. (2019). Searching for MobileNetV3. *Computer Vision and Pattern Recognition (CVPR)*, 1-11
- [12] Mark Sandler, A. H.-C. (2019). MobileNetV2: Inverted Residuals and Linear Bottlenecks. *arXiv:1801.04381v4 [cs.CV]*, 1-14.

- [13] Raden Shalehuddin Albawani, F. T. (2024). IMPLEMENTASI SEBLOCK PADA KLASIFIKASI CITRA PENYAKIT MATA MANUSIA DENGAN ARSITEKTUR MOBILENETV3-SMALL. *JATI (Jurnal Mahasiswa Teknik Informatika)*, 1123-1128.
- [14] Rizqy Joventus Gunawan, B. I. (2021). PENGENALAN EKSPRESI WAJAH BERBASIS CONVOLUTIONAL NEURAL NETWORK DENGAN MODEL ARSITEKTUR VGG16. *e-Proceeding of Engineering*, 6442-6454.
- [15] Rina. (2023, June 12). *Memahami Confusion Matrix: Accuracy, Precision, Recall, Specificity, dan F1-Score untuk Evaluasi Model Klasifikasi*. Diambil kembali dari Medium: <https://esairina.medium.com/memahami-confusion-matrix-accuracy-precision-recall-specificity-dan-f1-score-610d4f0db7cf>
- [16] Rifqi Alfaesta Prawiratama, S. I. (2024). RANCANG BANGUN APLIKASI UJI KEMIRIPAN GAMBAR AI GENERATIVE DAN GAMBAR BUATAN TANGAN MENGGUNAKAN METODE DEEP LEARNING. *JURNAL TEKINKOM*, 114-123.